TP : Pratique du modèle de régression logistique

Prédiction de la maladie cardio-vasculaire via un GLM Binomial(lien logit)

DAOUDI Adam - 2A DS

Institut National de Statistique et d'Économie Appliquée

Cours de *Modèle Linéaire Généralisé*

22 avril 2026

Plan de la présentation

1. Introduction
2. Problématique
3. Description des données
4. Analyse descriptive
5. Méthodologie
6. Résultats
7. Évaluation sur l'échantillon test
8. Interprétation
9. Conclusion

Contexte : du modèle linéaire au GLM

Le modèle linéaire classique $Y = X^\top \beta + \varepsilon$ repose sur :

- la **linéarité** $\mathbb{E}(Y) = X^\top \beta$;
- la **normalité** des erreurs $\varepsilon \sim \mathcal{N}(0, \sigma^2)$;
- l'**homoscédasticité** $\mathrm{Var}(Y) = \sigma^2$ constante.

Contexte : du modèle linéaire au GLM

Le modèle linéaire classique $Y = X^\top \beta + \varepsilon$ repose sur :

- la **linéarité** $\mathbb{E}(Y) = X^\top \beta$;
- la **normalité** des erreurs $\varepsilon \sim \mathcal{N}(0, \sigma^2)$;
- l'**homoscédasticité** $\mathrm{Var}(Y) = \sigma^2$ constante.

Problème : lorsque Y est binaire (malade / sain), positif (temps d'attente) ou de comptage (nb. sinistres), *aucune* de ces hypothèses n'est vérifiée.

Contexte : du modèle linéaire au GLM

Le modèle linéaire classique $Y = X^\top \beta + \varepsilon$ repose sur :

- la **linéarité** $\mathbb{E}(Y) = X^\top \beta$;
- la **normalité** des erreurs $\varepsilon \sim \mathcal{N}(0, \sigma^2)$;
- l'**homoscédasticité** $\mathrm{Var}(Y) = \sigma^2$ constante.

Problème : lorsque Y est binaire (malade / sain), positif (temps d'attente) ou de comptage (nb. sinistres), *aucune* de ces hypothèses n'est vérifiée. **Solution : les Modèles Linéaires Généralisés (Nelder & Wedderburn, 1972)**

1. Composante aléatoire : loi de la famille exponentielle ;
2. Composante déterministe : $\eta = X^\top \beta$;
3. Fonction de lien : $g(\mathbb{E}(Y)) = \eta$.

Cas binaire : la régression logistique

Si $Y_i \mid X_i \sim \mathcal{B}\big(\pi(x_i)\big)$, alors :

$$\mathbb{E}(Y_i \mid X_i) = \pi(x_i), \qquad \mathrm{Var}(Y_i \mid X_i) = \pi(x_i)\big(1 - \pi(x_i)\big).$$

La fonction de lien canonique est le **logit** :

$$\mathrm{logit}\big(\pi(x)\big) \;=\; \log\frac{\pi(x)}{1-\pi(x)} \;=\; \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

Cela garantit que $\pi(x) \in]0;1[$ et que :

$$\pi(x) = \frac{\exp(X^\top \beta)}{1 + \exp(X^\top \beta)} \quad \text{(fonction sigmoïde).}$$

Pourquoi le logit ?

- *Paramètre canonique* de la loi Bernoulli dans la famille exponentielle.
- Interprétation directe en **odds ratios** : $\mathrm{OR}_j = e^{\beta_j}$.
- Fournit des valeurs ajustées bornées entre 0 et 1.

Problématique médicale

Problématique

À partir de variables cliniques simples (âge, sexe, ECG, cholestérol, test d'effort ...) :

peut-on prédire la probabilité qu'un patient soit atteint d'une maladie cardio-vasculaire et en identifier les facteurs de risque dominants ?

Variable réponse binaire :

$$Y = \begin{cases} 1 & \text{présence d'une maladie coronarienne} \\ 0 & \text{absence} \end{cases}$$

Justification du choix :

- Les maladies cardio-vasculaires sont la **1re cause de mortalité** mondiale (OMS, 2023).
- Un modèle *interprétable* est requis par la pratique clinique.
- La régression logistique produit des **odds ratios** directement utilisables dans un contexte médical (epidemiology, évidence-based medicine).

Jeu de données : Cleveland Heart Disease

Source : UCI Machine Learning Repository (Detrano *et al.*, 1989).

- $n = 303$ patients (Cleveland Clinic Foundation)
- $p = 13$ variables explicatives cliniques
- 1 variable cible `num` $\in \{0, 1, 2, 3, 4\}$
- Après suppression des NA sur `ca` et `thal` : $n = 297$

Dichotomisation :

$$\texttt{chd} = \mathbb{1}\{\texttt{num} > 0\}$$

Répartition

CHD	Effectif	Prop.
0 (sain)	160	53.9 %
1 (malade)	137	46.1 %

$\Rightarrow$ Classes quasi-équilibrées $\Rightarrow$ pas besoin de *resampling*.

Dictionnaire des variables

Variable	Type	Description
`age`	quantitative	Âge du patient (années)
`sex`	qualitative 2	Sexe (M / F)
`cp`	qualitative 4	Type de douleur thoracique
`trestbps`	quantitative	Pression artérielle au repos (mm Hg)
`chol`	quantitative	Cholestérol sérique (mg/dL)
`fbs`	qualitative 2	Glycémie à jeun > 120 mg/dL
`restecg`	qualitative 3	ECG au repos
`thalach`	quantitative	Fréquence cardiaque max. atteinte
`exang`	qualitative 2	Angine induite par l'effort
`oldpeak`	quantitative	Dépression du segment ST à l'effort
`slope`	qualitative 3	Pente du segment ST
`ca`	quantitative	Nb. de gros vaisseaux colorés (0–3)
`thal`	qualitative 3	Thalassémie
`chd`	binaire	Variable réponse

Prétraitement : encodage *one-hot* des qualitatives (`drop_first=True` $\Rightarrow$ modalité de référence), standardisation des continues ($\mu = 0, \sigma = 1$).

Distribution de la variable réponse

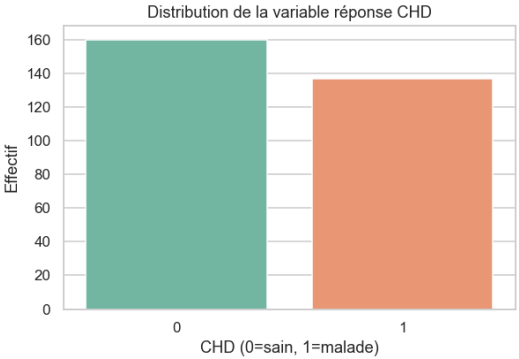

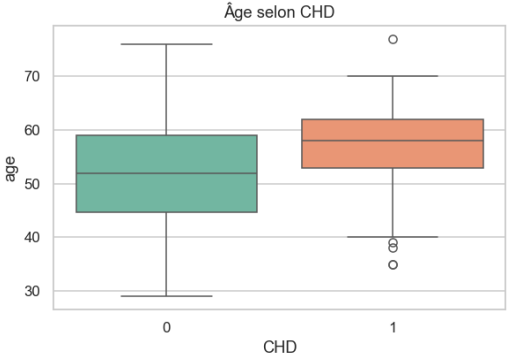

Constat : les malades sont en moyenne plus âgés (médiane $\approx$ 58 ans contre 52 ans chez les sains).

Variables quantitatives vs CHD

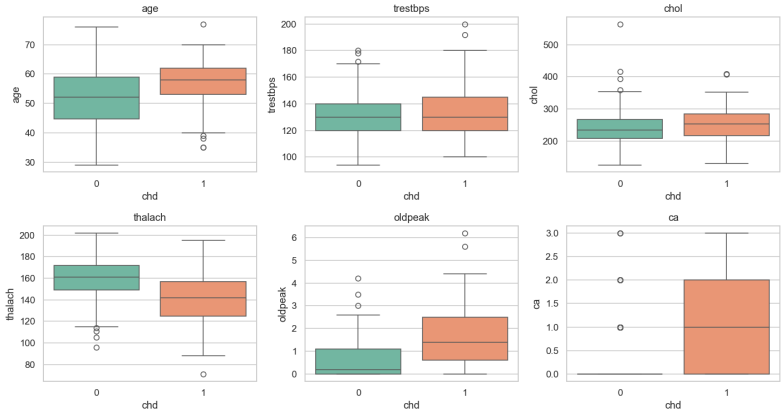

Lecture : `thalach` (fréq. cardiaque max.) diminue chez les malades ; `oldpeak`, `ca` et l'âge augmentent ; `chol` discrimine peu.

Variables qualitatives vs CHD

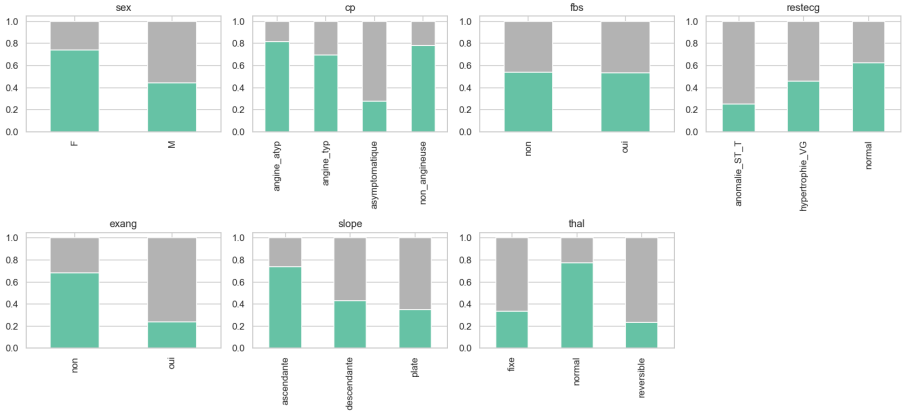

Les hommes, les patients avec `cp` = *asymptomatique*, `thal` = *réversible*, `exang` = oui, `slope` = *plate* sont fortement sur-représentés chez les malades.

Matrice de corrélation (quantitatives)

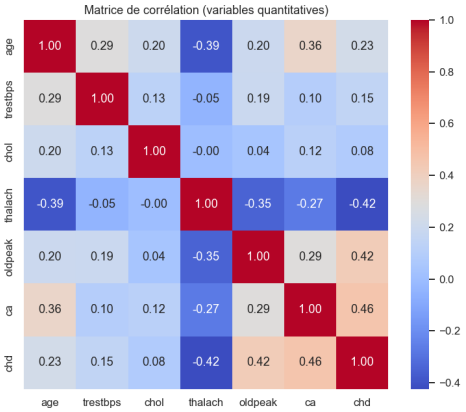

Corrélations modérées ($|\rho| < 0.5$) $\Rightarrow$ **pas de multi-colinéarité alarmante**, on peut conserver toutes les variables continues.

Échantillonnage stratifié 80 / 20

Pourquoi stratifier ? Préserver la proportion de malades dans *chaque* sous-échantillon (*cf. cours, Chapitre 3*).

	Taille	Prop. CHD = 1	Prop. CHD = 0
Échantillon d'apprentissage	237	**0.460**	0.540
Échantillon de validation	60	**0.467**	0.533

Justification opérationnelle

- Apprentissage = construction du modèle (IRLS, MLE).
- Validation = évaluation *hors échantillon* (ROC, AUC, matrice de confusion).
- `random_state=42` : résultats reproductibles.

Estimation par maximum de vraisemblance

La log-vraisemblance du modèle logistique s'écrit :

$$\ell(\beta) = \sum_{i=1}^{n} \Big[y_i X_i^\top \beta \; - \; \log\big(1 + e^{X_i^\top \beta}\big) \Big].$$

Le gradient $\nabla \ell(\beta) = \sum_i x_i \big(y_i - \pi(x_i)\big)$ est non-linéaire : pas de solution explicite.

Algorithme IRLS (Iterated Reweighted Least Squares)

$$\beta^{(t+1)} = \beta^{(t)} + I^{-1}\big(\beta^{(t)}\big)\, \nabla \ell\big(\beta^{(t)}\big)$$

où $I(\beta) = X^\top W X$ est la matrice d'information de Fisher, $W = \mathrm{diag}\big(\pi_i(1-\pi_i)\big)$.

Propriétés asymptotiques :

$$\hat{\beta} \xrightarrow{\mathcal{L}} \mathcal{N}\big(\beta, I^{-1}(\beta)\big) \quad \Rightarrow \quad \text{test de Wald : } Z_j = \hat{\beta}_j / \hat{\sigma}_{\hat{\beta}_j}.$$

Modèle complet : 18 prédicteurs

Indicateur	Valeur	Indicateur	Valeur
Log-vraisemblance ℓ	-80.14	AIC	198.28
Déviance D	160.28	BIC	264.18
Déviance nulle D_0	327.03	Pseudo-R^2	0.510
Df Model	18	Df Residuals	218

Observation : 10 coefficients sur 18 ont p-value > 0.2 ($\Rightarrow$ non-significatifs) : `age`, `chol`, `thalach`, `fbs`, `restecg`, etc.

$\Rightarrow$ Nécessité d'une sélection de variables.

Sélection *backward* AIC

Critère : $\mathrm{AIC} = -2\ell(\hat{\beta}) + 2p$ à minimiser.

Variables retirées successivement :

1. `restecg_hypertrophie_VG` → AIC = 196.28
2. `age` → 194.28
3. `thal_normal` → 192.30
4. `thalach` → 191.00
5. `fbs_oui` → 189.82
6. `chol` → 188.83
7. `slope_descendante` → 187.90
8. `exang_oui` → 187.54
9. `cp_angine_typ` → 187.15
10. `cp_non_angineuse` → **186.20**

Modèle retenu (8 variables) : `trestbps`, `oldpeak`, `ca`, `sex_M`, `cp_asymptomatique`, `restecg_normal`, `slope_plate`, `thal_reversible`.

Coefficients et odds ratios du modèle retenu

Variable	$\hat{\beta}$	$\mathrm{OR} = e^{\hat{\beta}}$	IC 95 %	p-value
(Intercept)	−2.371	0.09	[0.03 ; 0.30]	< 0.001 ***
`trestbps`	0.375	1.45	[0.98 ; 2.17]	0.065 .
`oldpeak`	0.646	**1.91**	[1.14 ; 3.20]	0.014 *
`ca`	0.898	**2.46**	[1.54 ; 3.93]	< 0.001 ***
`sex_M`	0.878	2.41	[0.94 ; 6.15]	0.067 .
`cp_asympt.`	1.915	**6.79**	[3.10 ; 14.87]	< 0.001 ***
`restecg_normal`	−0.758	0.47	[0.21 ; 1.05]	0.067 .
`slope_plate`	0.922	**2.51**	[1.07 ; 5.92]	0.035 *
`thal_reversible`	1.715	**5.56**	[2.37 ; 13.02]	< 0.001 ***

5 facteurs significatifs à 5 %, **3 facteurs** à la limite ($p \approx 0.07$).

Tests du rapport de vraisemblance (modèles emboîtés)

Test : $\Delta D = D_{\text{réduit}} - D_{\text{complet}} \xrightarrow{\mathcal{L}} \chi^2_{p_1 - p_0}$ sous H_0.

H_0	H_1	ΔD	ddl	Décision
M_{age}	M_{reduit}	149.28	7	H_0 rejetée ($p < 10^{-28}$)
M_{reduit}	M_{complet}	7.91	10	H_0 conservée ($p = 0.637$)

Conclusion

- Le modèle avec age seul est **insuffisant** : les autres variables apportent de l'information.
- Les 10 variables supplémentaires du modèle complet n'apportent **rien** de significatif.
- **On retient le modèle réduit** (parcimonie).

Adéquation du modèle

Statistique	M_{age}	M_{reduit}	M_{complet}
Déviance D	317.48	**168.19**	160.28
Ratio D / ddl	1.351	**0.738**	0.735
χ^2 Pearson / ddl	1.008	1.091	1.225
Pseudo-R^2	0.029	**0.486**	0.510
AIC	321.48	**186.20**	198.28
BIC	328.41	**217.41**	264.18
p-test de déviance	0.0003	**0.999**	0.999

Test d'Hosmer–Lemeshow ($g = 10$ déciles) sur M_{reduit} :

$$C^2 = 6.37, \quad \text{ddl} = 8, \quad p = 0.606.$$

Interprétation

- $p > 0.05$ pour les deux tests : **l'hypothèse d'adéquation n'est pas rejetée**.
- Ratio $D/\text{ddl} \approx 0.74 < 1$: *pas de sur-dispersion* (conforme au cours p. 109).

Analyse des résidus

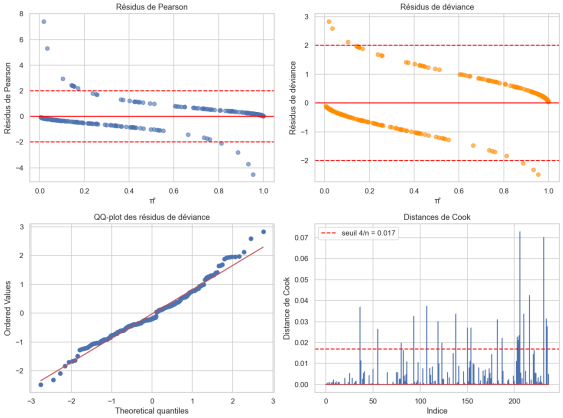

Diagnostic des résidus : chiffres clés

- $|r^{\text{Pearson}}| > 2$: **13 / 237** obs. (5.5 %, conforme à l'aléa gaussien).
- $|r^{\text{déviance}}| > 2$: **6 / 237** obs. (2.5 %).
- Leviers $h_{ii} > 2(p+1)/n = 0.076$: 24 observations (pas aberrant pour $n = 237$).
- **Distance de Cook max =** $0.073 \ll 1 \Rightarrow$ *aucune* observation n'exerce d'influence excessive.
- QQ-plot aligné $\Rightarrow$ normalité asymptotique des résidus de déviance acceptable.

Verdict

Le modèle est **statistiquement bien spécifié** : pas de tendance structurelle dans les résidus, pas d'observation à écarter.

Matrices de confusion (seuil = 0.5)

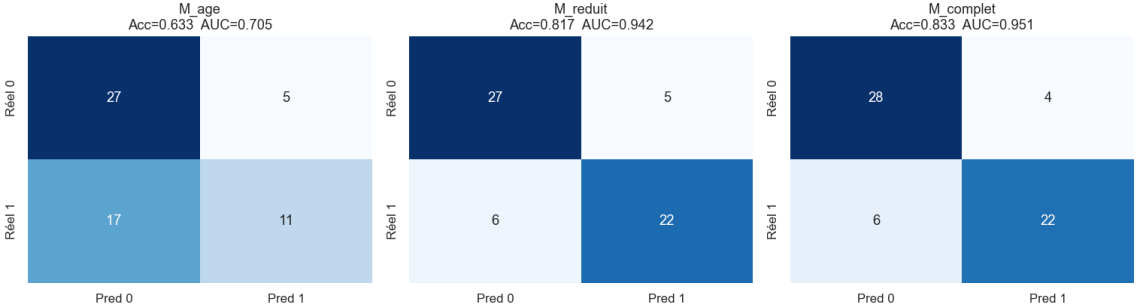

Modèle	Accuracy	Précision	Rappel	F1	AUC
M_{age}	0.633	0.688	0.393	0.500	0.705
M_{reduit}	**0.817**	0.815	**0.786**	**0.800**	**0.942**
M_{complet}	0.833	0.846	0.786	0.815	0.951

Courbe ROC : comparaison des modèles

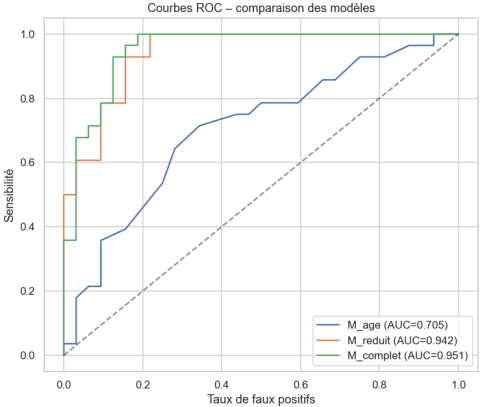

- M_{reduit} (AUC $= 0.942$) $\approx$ M_{complet} (AUC $= 0.951$) avec **la moitié des paramètres**.
- M_{age} (AUC $= 0.705$) manque 17 malades sur 28 (sensibilité $= 39\,\%$) : inacceptable cliniquement.

Comparaison des fonctions de lien

Fonction de lien $g(\mu)$	Déviance	AIC
logit $\log \dfrac{\mu}{1-\mu}$	168.19	186.19
probit $\Phi^{-1}(\mu)$	169.07	187.07
cloglog $\log\big(-\log(1-\mu)\big)$	**167.63**	**185.63**

Conclusion : les trois liens donnent des résultats quasi identiques (ΔAIC < 2).

Justification du choix du *logit*

- Lien **canonique** de la loi Bernoulli (cours p. 62, 79).
- Seul lien qui permet l'interprétation directe en **odds ratios**, convention médicale.
- Coefficients directement comparables à la littérature épidémiologique.

Interprétation clinique des *odds ratios*

- **cp = asymptomatique (OR = 6.8)** : les douleurs thoraciques silencieuses multiplient par ~ 7 la cote de maladie. Résultat cohérent (infarctus « silencieux »).
- **thal = réversible (OR = 5.6)** : déficit ischémique détecté au test d'effort $\Rightarrow$ marqueur direct d'ischémie myocardique.
- **ca (OR = 2.5 par écart-type)** : chaque vaisseau coronarien atteint supplémentaire multiplie par 2.5 la cote de maladie.
- **oldpeak (OR = 1.9)**, **slope = plate (OR = 2.5)** : anomalies ST à l'effort = risque accru.
- **sex = M (OR = 2.4 ;** $p = 0.067$**)** : effet homme limite-significatif.
- **restecg = normal (OR = 0.47)** : facteur *protecteur*.

Rappel : formule d'un *odds ratio*

$$\mathrm{OR}_j = \frac{\mathrm{odds}(X_j = x+1)}{\mathrm{odds}(X_j = x)} = e^{\beta_j}.$$

$\mathrm{OR} > 1$: *facteur de risque* ; $\mathrm{OR} < 1$: *facteur protecteur*.

Justification des choix méthodologiques

1. **Famille Binomiale(1, π)** : la réponse est binaire $\Rightarrow$ unique choix naturel dans la famille exponentielle.
2. **Lien logit** : lien canonique, interprétable en OR, différence faible avec probit/cloglog dans les données.
3. **Stratification 80/20** : préserve la proportion de malades ; classes suffisamment équilibrées donc pas d'oversampling.
4. **Standardisation** des variables continues : stabilité numérique IRLS + comparabilité des coefficients.
5. **Backward AIC** : compromis entre ajustement et parcimonie, test LR confirme le choix.
6. **Test d'Hosmer–Lemeshow** plutôt que déviance χ^2 pour données binaires individuelles (recommandation du cours p. 104).
7. **ROC/AUC** : métrique indépendante du seuil, adaptée aux classes potentiellement déséquilibrées.

Conclusion

Synthèse

- Le modèle retenu (**8 variables, AIC = 186.2**) :
  - Accuracy validation = **81.7 %**, AUC = **0.942**
  - Hosmer–Lemeshow $p = 0.61$ (adéquat)
  - Max Cook = 0.07 (aucune observation influente)
- Il est *statistiquement équivalent* au modèle complet (18 variables) tout en étant **deux fois plus parcimonieux**.
- Les facteurs de risque identifiés concordent avec la littérature cardiologique.

Leçons méthodologiques

- La régression logistique est à la fois **souple** (AUC > 0.94) et **rigoureuse** (tests d'adéquation).
- La démarche du cours *analyse* $\rightarrow$ *ajustement* $\rightarrow$ *tests* $\rightarrow$ *résidus* $\rightarrow$ *validation* est parfaitement opérationnelle.
- Python (`statsmodels`) reproduit fidèlement la sortie de la fonction `glm()` de R.

Perspectives

- **Validation croisée** (k-fold) pour des estimations plus robustes de l'AUC.
- Ajustement d'un modèle **Firth** (bias-reduced MLE) pour gérer les variables quasi-complètes.
- Comparaison à des modèles non-paramétriques (*random forest*, *gradient boosting*), en gardant la régression logistique comme **référence interprétable**.
- Inclusion de termes **d'interaction** (ex. sex $\times$ age) pour affiner la stratification par sexe.

Références I

- BADAOUI, F. (2026). *Modèle linéaire généralisé*, polycopié INSEA.
- Nelder, J. A. & Wedderburn, R. W. M. (1972). Generalized Linear Models. *J. Royal Statistical Society A*, **135**(3), 370–384.
- Detrano, R. *et al.* (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *American Journal of Cardiology*, **64**, 304–310.
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3e éd.). Wiley.
- McCullagh, P. & Nelder, J. (1989). *Generalized Linear Models* (2e éd.). Chapman & Hall.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley.
- UCI ML Repository — Heart Disease Data Set. `https://archive.ics.uci.edu/ml/datasets/Heart+Disease`
- `statsmodels` (2026). *Generalized Linear Models*. `https://www.statsmodels.org/`
- Pedregosa, F. *et al.* (2011). Scikit-learn : Machine Learning in Python. *JMLR* **12**, 2825–2830.

Merci de votre attention

Questions ?