Royaume du Maroc

Haut-Commissariat au Plan

Institut National de Statistique et d'Économie Appliquée

(INSEA)

Rapport de Travaux Pratiques

Module : *Modèle Linéaire Généralisé*

Pratique du modèle de régression logistique sous Python

Application à la prédiction de la maladie cardio-vasculaire

(Cleveland Heart Disease Dataset)

Réalisé par :

M. DAOUDI Adam

Encadré par :

Mme F. BADAOUI

Professeure à l'INSEA

Année Universitaire 2025–2026

22 avril 2026

Résumé

Ce rapport présente l'application d'un **Modèle Linéaire Généralisé Binomial avec fonction de lien logit** (régression logistique) à la prédiction de la maladie coronarienne sur le jeu de données *Cleveland Heart Disease* de l'UCI ML Repository (Detrano et al., 1989). Après une revue des fondements théoriques des GLM — famille exponentielle, estimation par maximum de vraisemblance via l'algorithme IRLS, tests de Wald et de rapport de vraisemblance, déviance, test d'Hosmer–Lemeshow, diagnostic par les résidus — la démarche d'analyse du cours (Mme Badaoui, INSEA, 2026) est appliquée pas à pas.

L'échantillon de 297 patients est découpé de manière stratifiée en 80 % d'apprentissage et 20 % de validation. Une sélection *backward* sur le critère AIC aboutit à un modèle à 8 variables explicatives dominé cliniquement par le type de douleur thoracique (OR = 6,8), la thalassémie réversible (OR = 5,6), le nombre de vaisseaux coronariens atteints (OR = 2,5) et la dépression du segment ST induite par l'effort (OR = 1,9). Le modèle satisfait l'ensemble des tests d'adéquation (Hosmer–Lemeshow $p = 0{,}61$, ratio $D/\text{ddl} = 0{,}74$) et atteint une **précision de 81,7 %** et une **AUC de 0,942** sur l'échantillon de validation.

Mots-clés : modèle linéaire généralisé, régression logistique, famille exponentielle, maximum de vraisemblance, déviance, test d'Hosmer–Lemeshow, odds ratio, courbe ROC, Python, statsmodels.

Table des matières

Résumé **3**

Table des figures **6**

Liste des tableaux **7**

1 Introduction **9**

1.1 Contexte 9

1.2 Objectifs du travail 10

1.3 Organisation du rapport 10

2 Problématique et choix du cas d'étude **11**

2.1 Contexte épidémiologique 11

2.2 Formulation de la problématique 11

2.3 Justification du choix de la régression logistique 11

3 Fondements théoriques du GLM logistique **13**

3.1 La famille exponentielle 13

3.2 Définition du GLM logistique 14

3.3 Estimation par maximum de vraisemblance 14

3.4 Tests d'hypothèses 15

3.4.1 Test de Wald (individuel) 15

3.4.2 Test du rapport de vraisemblance (TRV) 15

3.4.3 Intervalles de confiance 15

3.5 Adéquation du modèle 15

3.5.1 Déviance 15

3.5.2 Statistique du χ^2 de Pearson 15

3.5.3 Test d'Hosmer–Lemeshow 15

3.5.4 Pseudo-R^2, AIC et BIC 16

3.6 Diagnostic par les résidus 16

3.6.1 Résidus de Pearson et de déviance 16

3.6.2 Leviers et distances de Cook 16

3.7 Interprétation : *odds ratio* 16

4 Méthodologie et données **17**
4.1 Source et description des données . . . 17
4.1.1 Dictionnaire des variables . . . 17
4.1.2 Prétraitement . . . 17
4.1.3 Analyse descriptive de la variable réponse . . . 18
4.2 Analyse descriptive bivariée . . . 19
4.2.1 Variables quantitatives . . . 19
4.2.2 Variables qualitatives . . . 19
4.2.3 Structure de corrélation . . . 20
4.3 Protocole expérimental . . . 20
4.3.1 Échantillonnage stratifié 80 / 20 . . . 20
4.3.2 Stratégie de modélisation . . . 20
4.3.3 Environnement logiciel . . . 21

5 Résultats et discussion **22**
5.1 Modèle complet et sélection de variables . . . 22
5.1.1 Ajustement du modèle complet . . . 22
5.1.2 Sélection *backward* AIC . . . 22
5.1.3 Modèle retenu M_{reduit} . . . 23
5.2 Tests d'hypothèses . . . 23
5.2.1 Test du rapport de vraisemblance sur modèles emboîtés . . . 23
5.3 Adéquation du modèle . . . 24
5.4 Analyse des résidus . . . 25
5.5 Validation sur l'échantillon test . . . 26
5.5.1 Matrices de confusion . . . 26
5.5.2 Courbe ROC . . . 26
5.6 Comparaison des fonctions de lien . . . 27
5.7 Interprétation clinique . . . 27
5.8 Limites . . . 27

6 Conclusion **29**
6.1 Synthèse . . . 29
6.2 Performance du modèle retenu . . . 29
6.3 Contributions du travail . . . 30
6.4 Perspectives . . . 30

Bibliographie **31**

A Code Python utilisé **32**

Table des figures

4.1 Distribution de la variable réponse 18
4.2 Variables quantitatives vs CHD 19
4.3 Variables qualitatives vs CHD 19
4.4 Matrice de corrélation 20

5.1 Analyse des résidus 25
5.2 Matrices de confusion 26
5.3 Courbes ROC 26

Liste des tableaux

4.1 Description des variables du jeu Cleveland Heart Disease 17
4.2 Répartition de la variable réponse après nettoyage 18
4.3 Répartition après échantillonnage stratifié 20

5.1 Indicateurs d'ajustement du modèle complet 22
5.2 Séquence de retraits lors de la sélection backward AIC 23
5.3 Coefficients et odds ratios du modèle retenu M_{reduit} 23
5.4 Tests TRV sur modèles emboîtés 23
5.5 Comparaison des statistiques d'adéquation des trois modèles 24
5.6 Diagnostic des résidus du modèle retenu 25
5.7 Performances sur l'échantillon de validation 26
5.8 Comparaison de trois fonctions de lien sur le modèle retenu 27

Chapitre 1

Introduction

1.1 Contexte

L'étude quantitative du lien entre une variable à expliquer Y et un ensemble de variables explicatives $X_1, \ldots, X_p$ est l'objet central de la *modélisation statistique*. Lorsque la variable réponse est continue, à valeurs réelles et approximativement distribuée selon une loi normale, le **modèle linéaire classique** (régression multiple, analyse de la variance, analyse de la covariance) constitue l'outil de référence. Il fait les hypothèses fortes suivantes :

1. **Linéarité** : $\mathbb{E}(Y) = X^\top \beta$ (forme paramétrique) ;
2. **Normalité** : $\varepsilon = Y - X^\top \beta \sim \mathcal{N}(0, \sigma^2)$;
3. **Homoscédasticité** : $\mathrm{Var}(\varepsilon) = \sigma^2$ constante ;
4. **Indépendance** des observations.

Or dans de nombreuses situations pratiques, la variable réponse ne respecte pas ces hypothèses :

— *Variables binaires* : présence/absence d'une maladie, succès/échec d'un traitement, achat/non-achat d'un produit.

— *Variables de comptage* : nombre de sinistres, nombre d'appels téléphoniques, nombre de consultations médicales.

— *Variables positives dissymétriques* : durée de vie, temps d'attente, montant de sinistres.

Pour de telles situations, **Nelder et Wedderburn** ont introduit en 1972 [2] le cadre unifié des *Modèles Linéaires Généralisés* (GLM, *Generalized Linear Models*), qui étend le modèle linéaire classique via :

1. une **composante aléatoire** de loi appartenant à la *famille exponentielle* (Bernoulli, Binomiale, Poisson, Gamma, Normale, etc.) ;
2. une **composante déterministe** $\eta = X^\top \beta$, dite *prédicteur linéaire* ;
3. une **fonction de lien** $g(\cdot)$ monotone et dérivable telle que $g\big(\mathbb{E}(Y)\big) = \eta$.

Le cas particulier d'une variable réponse binaire avec lien logit constitue la **régression logistique**, qui fait l'objet de ce TP.

1.2 Objectifs du travail

Ce rapport poursuit trois objectifs complémentaires :

1. **Objectif pédagogique :** appliquer l'ensemble des étapes de modélisation enseignées dans le cours (analyse descriptive, échantillonnage stratifié, ajustement par maximum de vraisemblance, tests d'hypothèses, adéquation, diagnostic des résidus, comparaison de modèles) sur un cas d'étude concret.
2. **Objectif opérationnel :** démontrer que la démarche théorique présentée en R peut être reproduite *à l'identique* en Python via la bibliothèque `statsmodels`, dont la fonction `GLM` fournit une sortie directement comparable à la fonction `glm()` de R.
3. **Objectif scientifique :** construire un modèle prédictif interprétable de la maladie coronarienne en identifiant les facteurs de risque statistiquement significatifs, dans un esprit *d'evidence-based medicine*.

1.3 Organisation du rapport

Ce rapport est structuré en six chapitres :

— Le **Chapitre 2** formalise la problématique médicale et justifie le choix d'un modèle logistique.

— Le **Chapitre 3** détaille le cadre théorique du GLM logistique tel que présenté dans le cours : famille exponentielle, fonction de lien canonique, vraisemblance, tests, adéquation.

— Le **Chapitre 4** présente la méthodologie mise en œuvre : source des données, prétraitement, outils logiciels, protocole expérimental.

— Le **Chapitre 5** expose les résultats obtenus (estimation, tests, diagnostic, validation) et discute leur interprétation clinique.

— Le **Chapitre 6** conclut en synthétisant les apports et les limites du travail.

— L'**Annexe** fournit le code Python complet utilisé pour reproduire l'ensemble des résultats.

Chapitre 2

Problématique et choix du cas d'étude

2.1 Contexte épidémiologique

Les maladies cardio-vasculaires (MCV) constituent la **première cause de mortalité mondiale** selon l'Organisation Mondiale de la Santé, avec environ 17,9 millions de décès annuels. Parmi elles, la *maladie coronarienne* (Coronary Heart Disease, CHD) représente à elle seule près de 50 % de ces décès.

L'un des enjeux majeurs de santé publique est l'**identification précoce des patients à risque** à partir de variables mesurables lors d'une consultation cardiologique standard : données démographiques (âge, sexe), mesures physiologiques (pression artérielle, fréquence cardiaque maximale), résultats d'examens sanguins (cholestérol, glycémie) et résultats d'examens fonctionnels (électrocardiogramme, test d'effort, fluoroscopie).

2.2 Formulation de la problématique

Problématique :
À partir d'un ensemble de variables cliniques disponibles lors d'une consultation de routine, est-il possible de construire un modèle statistique qui :

- prédit *avec une bonne précision* la probabilité qu'un patient soit atteint d'une maladie coronarienne ;
- identifie les *facteurs de risque statistiquement significatifs* ;
- fournit une *interprétation clinique directement exploitable* ?

2.3 Justification du choix de la régression logistique

Plusieurs familles de modèles auraient pu répondre à cette question (arbres de décision, forêts aléatoires, réseaux de neurones, machines à vecteurs de support). Le choix s'est porté sur la **régression logistique** pour les raisons suivantes, alignées avec les besoins cliniques :

1. **Cohérence avec le cadre du cours.** Le TP demande l'application d'un GLM, dont la régression logistique est le représentant naturel pour une variable réponse binaire.

2. **Interprétabilité.** Les coefficients du modèle logistique se transforment en *odds ratios* (OR) via $\mathrm{OR}_j = e^{\beta_j}$, lecture universellement utilisée en épidémiologie et en médecine factuelle.
3. **Assomptions probabilistes claires.** Le modèle produit une *vraie probabilité* $\pi(x) \in [0, 1]$, pas seulement un score, ce qui autorise la comparaison à un seuil de décision médicale explicite.
4. **Inférence fréquentiste complète.** Disponibilité d'intervalles de confiance asymptotiques, de tests de Wald et de rapport de vraisemblance, d'outils d'adéquation (déviance, Hosmer–Lemeshow), d'analyse des résidus.
5. **Robustesse.** Peu de paramètres à estimer, résultats stables même avec un effectif modeste (quelques centaines de patients), pas de nécessité de *tuning* d'hyperparamètres.

Chapitre 3

Fondements théoriques du GLM logistique

Ce chapitre résume les éléments théoriques du cours (Mme F. Badaoui, INSEA, 2026) [1] indispensables à la compréhension des choix méthodologiques effectués dans le présent travail.

3.1 La famille exponentielle

Définition 3.1 (Famille exponentielle)**.** Une loi de probabilité de paramètres (θ, φ) appartient à la *famille exponentielle* si sa densité s'écrit sous la forme

$$f(y;\theta,\varphi) \;=\; \exp\left\{\frac{y\theta - b(\theta)}{a(\varphi)} + c(y,\varphi)\right\}, \tag{3.1}$$

où $a(\cdot)$, $b(\cdot)$, $c(\cdot)$ sont des fonctions connues, b deux fois dérivable et b' inversible. Le paramètre θ est dit *naturel* ou *canonique*, et φ est un paramètre de *dispersion* ou de *nuisance*.

Propriété 3.1 (Moments d'une loi de la famille exponentielle)**.** Si Y suit la loi donnée par (3.1), alors

$$\mathbb{E}(Y) = \mu = b'(\theta), \tag{3.2}$$

$$\mathrm{Var}(Y) = b''(\theta)\, a(\varphi). \tag{3.3}$$

Cas de la loi de Bernoulli. Pour $Y \sim \mathcal{B}(\pi)$, $\mathbb{P}(Y = y) = \pi^y(1-\pi)^{1-y}$, on peut réécrire :

$$f(y;\pi) = \exp\left\{y \log\frac{\pi}{1-\pi} + \log(1-\pi)\right\},$$

d'où l'identification :

$$\theta = \log\frac{\pi}{1-\pi} = \mathrm{logit}(\pi), \qquad b(\theta) = \log(1+e^{\theta}), \qquad a(\varphi) = 1.$$

Le *paramètre canonique* de la loi Bernoulli est donc le **logit** de la probabilité de succès, ce qui justifie théoriquement le choix de cette fonction de lien.

3.2 Définition du GLM logistique

Soient $(Y_i, X_i)_{i=1,\dots,n}$ un échantillon de n observations, avec $X_i = (X_{i,1}, \dots, X_{i,p})^\top$. Un GLM logistique suppose :

$$\begin{cases} Y_i \mid X_i \sim \mathcal{B}(\pi(x_i)), \\ \operatorname{logit}(\pi(x_i)) = \log \dfrac{\pi(x_i)}{1-\pi(x_i)} = \beta_0 + \displaystyle\sum_{j=1}^{p} \beta_j x_{i,j}. \end{cases} \tag{3.4}$$

La fonction de réponse (inverse du lien) est la *sigmoïde* :

$$\pi(x) \;=\; \frac{\exp(X^\top \beta)}{1+\exp(X^\top \beta)} \;\in\;]0;1[. \tag{3.5}$$

Remarque 3.1. Alternativement, on peut utiliser d'autres fonctions de lien comme le *probit* $g(\mu) = \Phi^{-1}(\mu)$ ou le *complementary log-log* $g(\mu) = \log(-\log(1-\mu))$. Le logit reste cependant le lien canonique et offre la meilleure interprétabilité.

3.3 Estimation par maximum de vraisemblance

La log-vraisemblance du modèle s'écrit :

$$\begin{aligned} \ell(\beta) &= \sum_{i=1}^{n} \Big[y_i \log \pi(x_i) + (1-y_i) \log\big(1-\pi(x_i)\big) \Big] \\ &= \sum_{i=1}^{n} \Big[y_i\, X_i^\top \beta - \log(1+e^{X_i^\top \beta}) \Big]. \end{aligned} \tag{3.6}$$

Le gradient (*score*) est :

$$\nabla \ell(\beta) = \sum_{i=1}^{n} X_i (y_i - \pi(x_i)). \tag{3.7}$$

Les équations de vraisemblance $\nabla \ell(\beta) = 0$ sont *non linéaires* en β : il n'existe pas de solution explicite. On a recours à l'algorithme **IRLS (Iterated Reweighted Least Squares)**, équivalent d'une méthode de Newton-Raphson sur l'information de Fisher :

$$\beta^{(t+1)} = \beta^{(t)} + \big[I(\beta^{(t)})\big]^{-1} \nabla \ell(\beta^{(t)}), \tag{3.8}$$

où la matrice d'information de Fisher vaut

$$I(\beta) = X^\top W X, \qquad W = \operatorname{diag}\big(\pi_i(1-\pi_i)\big). \tag{3.9}$$

Propriété 3.2 (Propriétés asymptotiques du MLE)**.** Sous des conditions de régularité, l'estimateur du maximum de vraisemblance $\hat{\beta}$ est convergent, asymptotiquement sans biais, et

$$\sqrt{n}\,(\hat{\beta} - \beta) \;\xrightarrow[n\to\infty]{\mathcal{L}}\; \mathcal{N}\big(0, I^{-1}(\beta)\big). \tag{3.10}$$

3.4 Tests d'hypothèses

3.4.1 Test de Wald (individuel)

Pour tester $H_0 : \beta_j = 0$ contre $H_1 : \beta_j \neq 0$,

$$Z_j = \frac{\hat{\beta}_j}{\hat{\sigma}_{\hat{\beta}_j}} \xrightarrow[H_0]{\mathcal{L}} \mathcal{N}(0,1), \qquad W_j = Z_j^2 \xrightarrow[H_0]{\mathcal{L}} \chi^2_1. \tag{3.11}$$

3.4.2 Test du rapport de vraisemblance (TRV)

Soient $M_0 \subset M_1$ deux modèles emboîtés. Sous $H_0 = \{M_0\}$, la statistique

$$T = -2 \log \frac{L(\hat{\beta}_0)}{L(\hat{\beta}_1)} = 2\big[\ell(\hat{\beta}_1) - \ell(\hat{\beta}_0)\big] = D_0 - D_1 \xrightarrow[H_0]{\mathcal{L}} \chi^2_{p_1 - p_0}. \tag{3.12}$$

3.4.3 Intervalles de confiance

Un IC asymptotique de niveau $1-\alpha$ pour β_j est :

$$\mathrm{IC}_{1-\alpha}(\beta_j) = \hat{\beta}_j \pm z_{1-\alpha/2}\, \hat{\sigma}_{\hat{\beta}_j}, \tag{3.13}$$

et pour l'odds ratio $\mathrm{OR}_j = e^{\beta_j}$:

$$\mathrm{IC}_{1-\alpha}(\mathrm{OR}_j) = \exp\Big(\hat{\beta}_j \pm z_{1-\alpha/2}\, \hat{\sigma}_{\hat{\beta}_j}\Big). \tag{3.14}$$

3.5 Adéquation du modèle

3.5.1 Déviance

Définition 3.2 (Déviance)**.** Soit ℓ_{sat} la log-vraisemblance du *modèle saturé* (n paramètres, $\hat{\mu}_i = y_i$). La *déviance* du modèle ajusté est :

$$D = 2(\ell_{\text{sat}} - \ell_{\hat{\beta}}) = 2 \sum_{i=1}^{n} \left\{ y_i \log \frac{y_i}{\hat{\mu}_i} + (1-y_i) \log \frac{1-y_i}{1-\hat{\mu}_i} \right\}. \tag{3.15}$$

Sous l'hypothèse d'adéquation, $D \sim \chi^2_{n-p-1}$ (asymptotique). Le modèle est jugé satisfaisant si $D/\mathrm{ddl} \lesssim 1$.

3.5.2 Statistique du χ^2 de Pearson

$$\chi^2_P = \sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i(1-\hat{\mu}_i)} \sim \chi^2_{n-p-1}. \tag{3.16}$$

3.5.3 Test d'Hosmer–Lemeshow

Recommandé dans le cours (p. 104) pour des données binaires individuelles. Les probabilités prédites $\hat{\pi}_i$ sont ordonnées et partitionnées en $K = 10$ groupes de taille approximativement

égale. Pour chaque groupe k, on note m_k l'effectif, o_k le nombre de succès observés, $\bar{\mu}_k$ la moyenne des $\hat{\pi}$. La statistique

$$C^2 = \sum_{k=1}^{K} \frac{(o_k - m_k\bar{\mu}_k)^2}{m_k\bar{\mu}_k(1-\bar{\mu}_k)} \xrightarrow[H_0]{\mathcal{L}} \chi^2_{K-2} \tag{3.17}$$

permet de tester l'adéquation : on *conserve* H_0 (modèle adéquat) si p-value $> 0{,}05$.

3.5.4 Pseudo-R^2, AIC et BIC

$$\text{Pseudo-}R^2 = \frac{D_0 - D}{D_0}, \quad \text{AIC} = -2\ell(\hat{\beta}) + 2p, \quad \text{BIC} = -2\ell(\hat{\beta}) + p\log(n). \tag{3.18}$$

3.6 Diagnostic par les résidus

3.6.1 Résidus de Pearson et de déviance

$$r_i^P = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\mu}_i(1-\hat{\mu}_i)}}, \quad r_i^D = \text{signe}(y_i - \hat{\mu}_i)\sqrt{d_i}, \tag{3.19}$$

où d_i est la contribution individuelle à la déviance. Une observation telle que $|r_i| > 2$ mérite attention.

3.6.2 Leviers et distances de Cook

Le *levier* h_{ii} est le i-ème terme diagonal de la matrice $H = X(X^\top WX)^{-1}X^\top W$. Un point est influent si $h_{ii} > 2(p+1)/n$. La *distance de Cook* mesure l'impact global sur les coefficients :

$$D_i \approx \frac{(r_i^P)^2\, h_{ii}}{p(1-h_{ii})^2}. \tag{3.20}$$

Alerte si $D_i > 1$.

3.7 Interprétation : *odds ratio*

Pour une variable binaire X_j et des autres covariables fixées :

$$\text{OR}_j = \frac{\text{odds}(X_j = 1)}{\text{odds}(X_j = 0)} = \exp(\beta_j). \tag{3.21}$$

OR > 1 indique un *facteur de risque* ; OR < 1 un *facteur protecteur*. Pour une variable continue, OR_j représente la multiplication de la cote par e^{β_j} pour une augmentation d'une unité de X_j.

Chapitre 4

Méthodologie et données

4.1 Source et description des données

Le jeu de données est le célèbre **Cleveland Heart Disease Dataset** de l'UCI Machine Learning Repository [7], issu des travaux cliniques de Detrano *et al.* [4]. Il rassemble **303 patients** de la *Cleveland Clinic Foundation* caractérisés par 13 variables cliniques plus une variable cible.

4.1.1 Dictionnaire des variables

Table 4.1 – Description des variables du jeu Cleveland Heart Disease

Variable	Type	Description
`age`	Quantitative	Âge du patient (années)
`sex`	Qualitative (2)	Sexe : Masculin / Féminin
`cp`	Qualitative (4)	Type de douleur thoracique
`trestbps`	Quantitative	Pression artérielle au repos (mm Hg)
`chol`	Quantitative	Cholestérol sérique (mg/dL)
`fbs`	Qualitative (2)	Glycémie à jeun > 120 mg/dL
`restecg`	Qualitative (3)	ECG au repos
`thalach`	Quantitative	Fréquence cardiaque max. atteinte
`exang`	Qualitative (2)	Angine induite par l'effort
`oldpeak`	Quantitative	Dépression du segment ST à l'effort
`slope`	Qualitative (3)	Pente du segment ST
`ca`	Quantitative (0–3)	Nb. de gros vaisseaux colorés
`thal`	Qualitative (3)	Thalassémie (normal/fixe/réversible)
`chd`	**Binaire**	**Variable réponse (dichotomisée)**

4.1.2 Prétraitement

1. **Nettoyage :** 6 observations présentant des valeurs manquantes sur `ca` ou `thal` sont supprimées (taille finale : $n = 297$).
2. **Dichotomisation :** $\texttt{chd} = \mathbb{1}\{\texttt{num} > 0\}$.

3. **Recodage :** les modalités numériques des qualitatives sont converties en libellés textuels pour plus de lisibilité.

4. **Encodage *one-hot*** avec suppression de la modalité de référence (`drop_first=True`), équivalent du codage *treatment contrast* utilisé par défaut dans R.

5. **Standardisation** ($\mu = 0$, $\sigma = 1$) des variables continues pour améliorer la stabilité numérique de l'IRLS et la comparabilité des coefficients.

4.1.3 Analyse descriptive de la variable réponse

Table 4.2 – Répartition de la variable réponse après nettoyage

CHD	Effectif	Proportion
0 (sain)	160	53,9 %
1 (malade)	137	46,1 %
Total	**297**	**100 %**

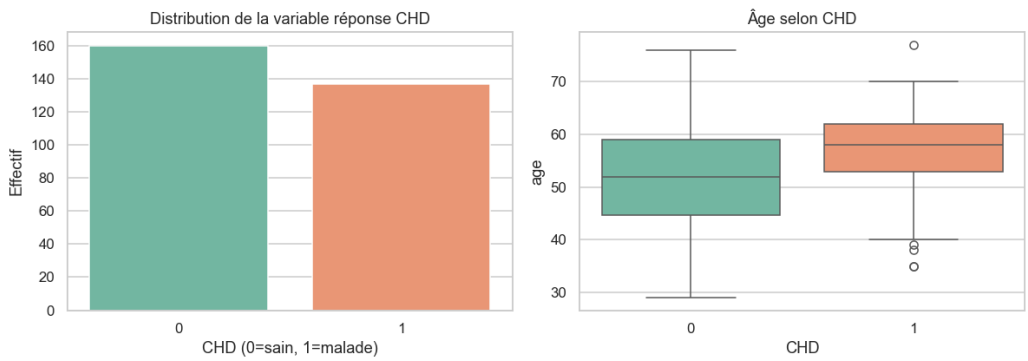

Figure 4.1 – Distribution de la variable réponse CHD et distribution de l'âge selon le statut de santé. L'âge médian est plus élevé chez les malades ($\approx$ 58 ans) que chez les sains ($\approx$ 52 ans).

Les classes sont *quasi-équilibrées* (46,1 % contre 53,9 %) : aucun rééquilibrage (oversampling, SMOTE) n'est nécessaire. Un échantillonnage stratifié suffit à préserver la répartition dans les sous-échantillons.

4.2 Analyse descriptive bivariée

4.2.1 Variables quantitatives

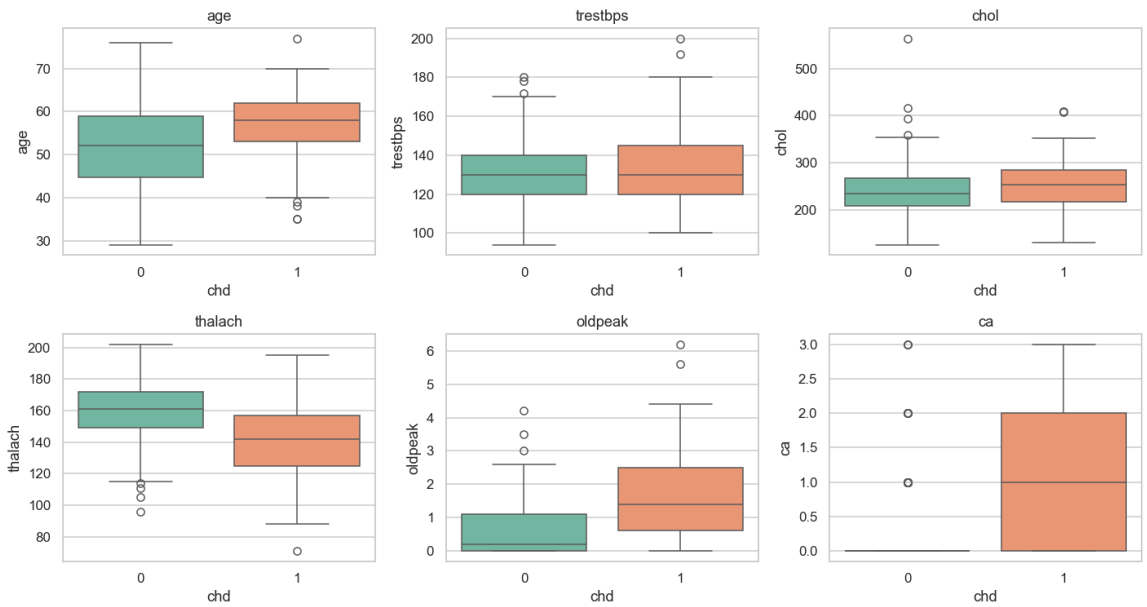

Figure 4.2 – Boxplots des variables quantitatives selon le statut CHD. La fréquence cardiaque maximale (`thalach`) est nettement plus faible chez les malades. `oldpeak` et le nombre de vaisseaux atteints (`ca`) augmentent fortement avec la maladie.

4.2.2 Variables qualitatives

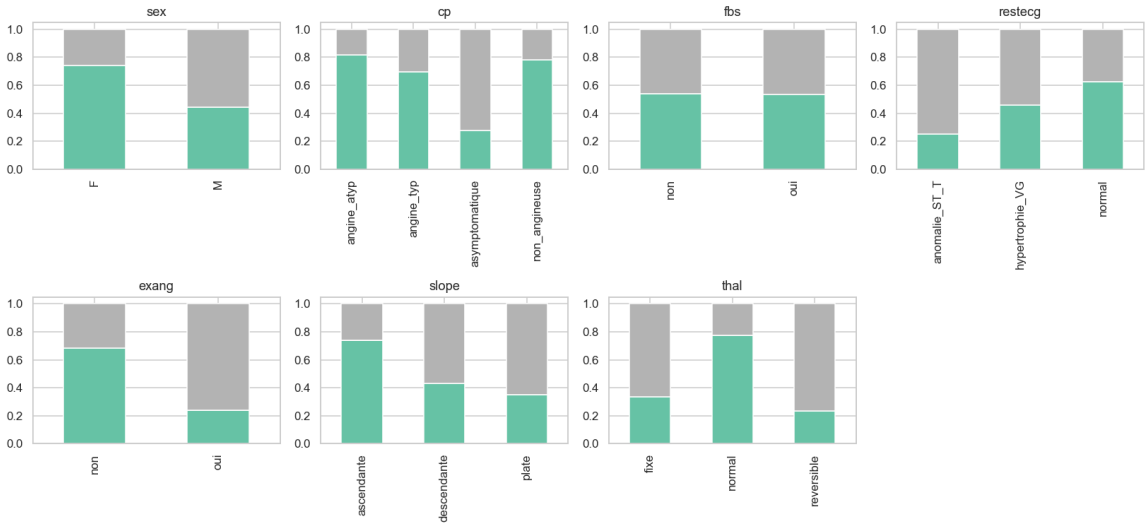

Figure 4.3 – Proportion de malades conditionnellement à chaque modalité des variables qualitatives. Les hommes, les patients à `cp = asymptomatique`, `thal = réversible`, `exang = oui` et `slope = plate` présentent une probabilité de maladie nettement plus élevée.

4.2.3 Structure de corrélation

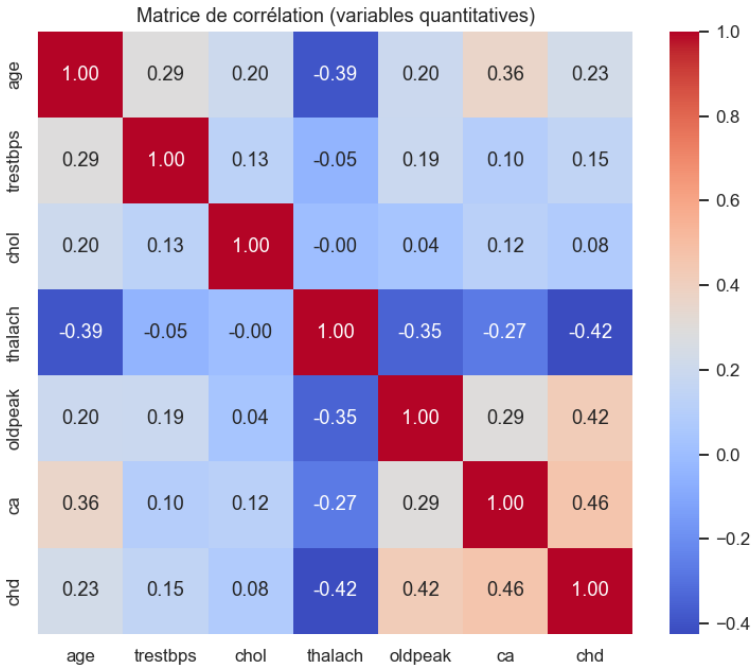

Figure 4.4 – Matrice de corrélation des variables quantitatives avec la réponse CHD. Les corrélations linéaires restent modérées ($|\rho| < 0{,}5$) : aucune multi-colinéarité alarmante.

4.3 Protocole expérimental

4.3.1 Échantillonnage stratifié 80 / 20

Le cours recommande un échantillonnage stratifié pour conserver *exactement* la répartition de la variable réponse dans les deux sous-échantillons. Cette précaution est d'autant plus importante que la taille d'échantillon est modeste.

Table 4.3 – Répartition après échantillonnage stratifié

Échantillon	Taille	Prop. CHD = 1	Prop. CHD = 0
Apprentissage	237	0,460	0,540
Validation	60	0,467	0,533

La fonction `train_test_split` de scikit-learn, appelée avec `stratify=y` et `random_state=42`, assure une découpe déterministe et reproductible.

4.3.2 Stratégie de modélisation

Trois modèles sont construits pour les fins de la comparaison :

— M_{age} : $\text{logit}(\pi) = \beta_0 + \beta_1 \cdot \texttt{age}$ (modèle simple analogue à l'exemple CHD du cours).

— M_{complet} : les 18 variables encodées.

— M_{reduit} : modèle issu de la sélection *backward AIC* à partir de M_{complet}.

4.3.3 Environnement logiciel

— Python 3.11, environnement conda `datasci`

— `statsmodels` 0.14 — classe `GLM` équivalente à `glm()` de R

— `scikit-learn` 1.3 — `train_test_split`, `StandardScaler`, métriques de classification

— `pandas`, `numpy`, `scipy.stats` — manipulation et distributions

— `matplotlib`, `seaborn` — visualisations

Chapitre 5

Résultats et discussion

5.1 Modèle complet et sélection de variables

5.1.1 Ajustement du modèle complet

Le modèle M_{complet} comprend les 18 variables (indicatrices comprises). L'algorithme IRLS converge en 6 itérations. Les principales statistiques sont :

Table 5.1 – Indicateurs d'ajustement du modèle complet

Indicateur	Valeur	Indicateur	Valeur
Log-vraisemblance ℓ	$-80{,}14$	AIC	198,28
Déviance D	160,28	BIC	264,18
Déviance nulle D_0	327,03	Pseudo-R^2	0,510
Df Model	18	Df Residuals	218

Parmi les 18 coefficients, 10 ont une p-value supérieure à 0,2, suggérant qu'ils n'apportent pas de contribution significative. Une sélection de variables s'impose.

5.1.2 Sélection *backward* AIC

La procédure retire itérativement la variable dont le retrait améliore le plus l'AIC, jusqu'à ce qu'aucun retrait n'améliore plus le critère.

Table 5.2 – Séquence de retraits lors de la sélection backward AIC

Étape	Variable retirée	AIC obtenu
1	`restecg_hypertrophie_VG`	196,28
2	`age`	194,28
3	`thal_normal`	192,30
4	`thalach`	191,00
5	`fbs_oui`	189,82
6	`chol`	188,83
7	`slope_descendante`	187,90
8	`exang_oui`	187,54
9	`cp_angine_typ`	187,15
10	`cp_non_angineuse`	**186,20**

5.1.3 Modèle retenu M_{reduit}

Table 5.3 – Coefficients et odds ratios du modèle retenu M_{reduit}

Variable	$\hat{\beta}$	OR $= e^{\hat{\beta}}$	IC 95 %	p-value
(Intercept)	−2,371	0,09	[0,03 ; 0,30]	< 0,001 ***
`trestbps`	0,375	1,45	[0,98 ; 2,17]	0,065
`oldpeak`	0,646	**1,91**	[1,14 ; 3,20]	0,014 *
`ca`	0,898	**2,46**	[1,54 ; 3,93]	< 0,001 ***
`sex_M`	0,878	2,41	[0,94 ; 6,15]	0,067
`cp_asymptomatique`	1,915	**6,79**	[3,10 ; 14,87]	< 0,001 ***
`restecg_normal`	−0,758	0,47	[0,21 ; 1,05]	0,067
`slope_plate`	0,922	**2,51**	[1,07 ; 5,92]	0,035 *
`thal_reversible`	1,715	**5,56**	[2,37 ; 13,02]	< 0,001 ***

Codes de signification : $*\ p < 0{,}05$, $**\ p < 0{,}01$, $***\ p < 0{,}001$.

5.2 Tests d'hypothèses

5.2.1 Test du rapport de vraisemblance sur modèles emboîtés

Table 5.4 – Tests TRV sur modèles emboîtés

H_0	H_1	ΔD	ddl	Décision
M_{age}	M_{reduit}	149,28	7	H_0 rejetée ($p < 10^{-28}$)
M_{reduit}	M_{complet}	7,91	10	H_0 conservée ($p = 0{,}637$)

Conclusion : le modèle à une variable est insuffisant, mais les 10 variables supplémentaires du modèle complet n'apportent aucune information significative par rapport au modèle réduit. On retient donc M_{reduit} en vertu du principe de parcimonie.

5.3 Adéquation du modèle

Table 5.5 – Comparaison des statistiques d'adéquation des trois modèles

Statistique	M_{age}	M_{reduit}	M_{complet}
Déviance D	317,48	**168,19**	160,28
Ratio D / ddl	1,351	**0,738**	0,735
χ^2 Pearson / ddl	1,008	1,091	1,225
Déviance nulle D_0	327,03	327,03	327,03
Pseudo-R^2	0,029	**0,486**	0,510
AIC	321,48	**186,20**	198,28
BIC	328,41	**217,41**	264,18
p-test de déviance	$3{\cdot}10^{-4}$	0,999	0,999

Test d'Hosmer–Lemeshow ($K = 10$ groupes, modèle réduit) :

$$C^2 = 6{,}37, \quad \text{ddl} = 8, \quad p\text{-value} = 0{,}606.$$

Synthèse de l'adéquation.

- Ratio $D/\text{ddl} = 0{,}74 < 1$: *pas de sur-dispersion.*
- p-value du test de déviance $> 0{,}05$: hypothèse d'adéquation non rejetée.
- Hosmer–Lemeshow $p = 0{,}61$: concordance entre prédictions et observations au sein des déciles de risque.
- Pseudo-$R^2 = 0{,}486$: le modèle explique environ 49 % de la déviance, ce qui est très correct pour des données cliniques.

5.4 Analyse des résidus

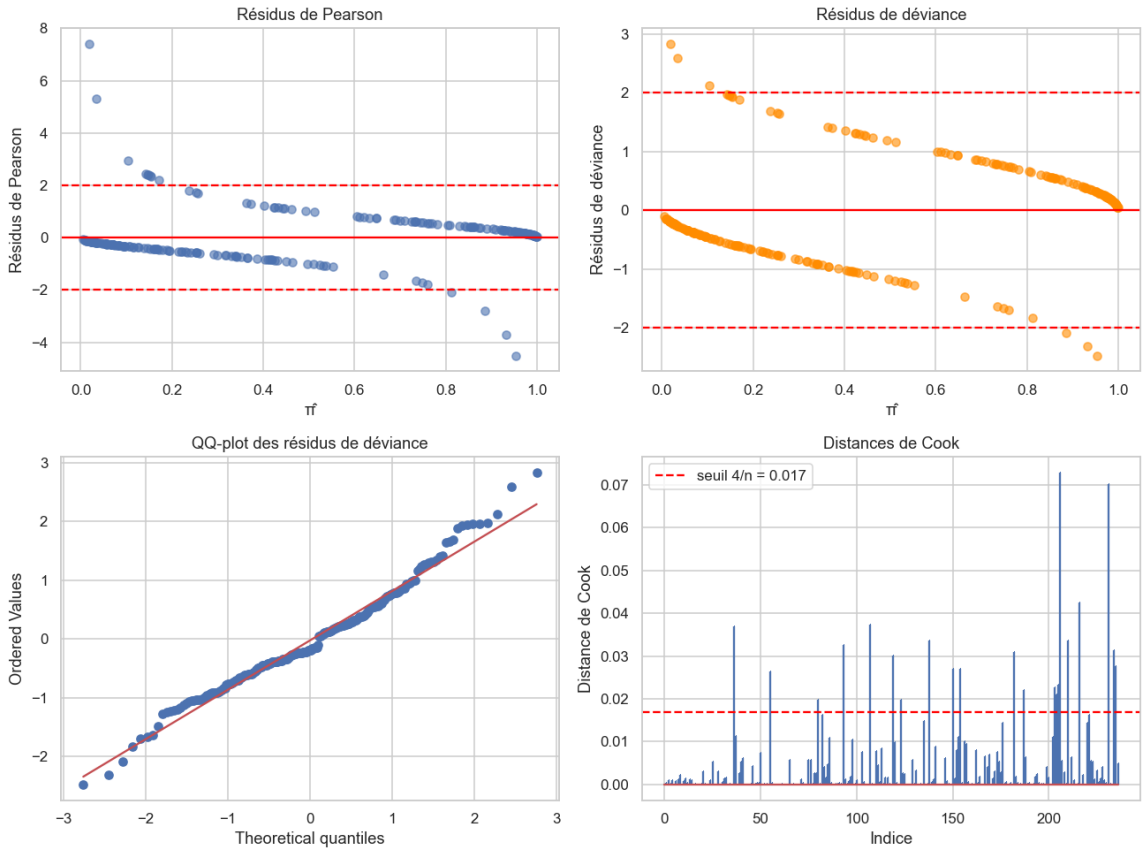

Figure 5.1 – Diagnostics du modèle retenu. En haut : résidus de Pearson et de déviance en fonction des valeurs ajustées $\hat{\pi}$; les lignes pointillées représentent les seuils ± 2. En bas à gauche : QQ-plot normal des résidus de déviance. En bas à droite : distances de Cook (max = 0,073).

Table 5.6 – Diagnostic des résidus du modèle retenu

Indicateur	Valeur
$\lvert r^{\text{Pearson}} \rvert > 2$	13 / 237 observations (5,5 %)
$\lvert r^{\text{déviance}} \rvert > 2$	6 / 237 observations (2,5 %)
Seuil de levier $2(p+1)/n$	0,076
Nb. d'observations $h_{ii} > 0{,}076$	24
Distance de Cook maximale	**0,073** (alerte si > 1)

Conclusion : aucune observation n'exerce d'influence excessive sur l'estimation des paramètres ; la proportion de résidus au-delà de ± 2 est conforme à l'aléa gaussien ; le QQ-plot confirme la normalité asymptotique. Le modèle est statistiquement bien spécifié.

5.5 Validation sur l'échantillon test

5.5.1 Matrices de confusion

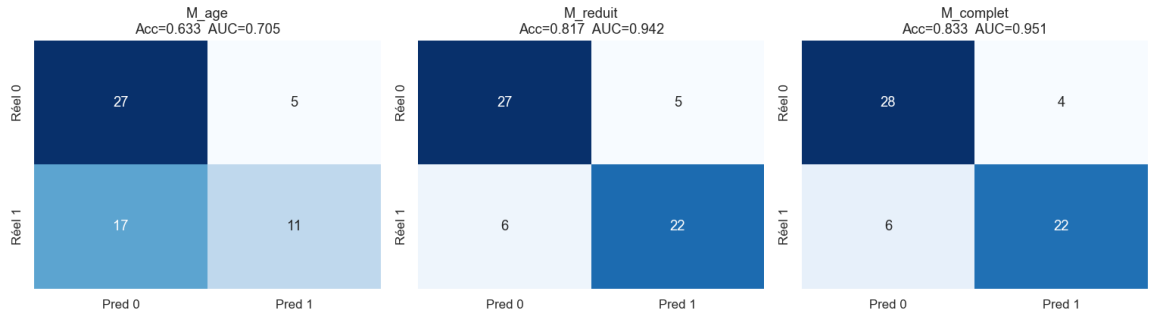

Figure 5.2 – Matrices de confusion obtenues au seuil $\pi = 0{,}5$ sur l'échantillon de validation ($n = 60$). Les prédictions du modèle réduit sont quasiment identiques à celles du modèle complet.

Table 5.7 – Performances sur l'échantillon de validation

Modèle	Accuracy	Précision	Rappel	F1	AUC
M_{age}	0,633	0,688	0,393	0,500	0,705
M_{reduit}	**0,817**	0,815	**0,786**	**0,800**	**0,942**
M_{complet}	0,833	0,846	0,786	0,815	0,951

5.5.2 Courbe ROC

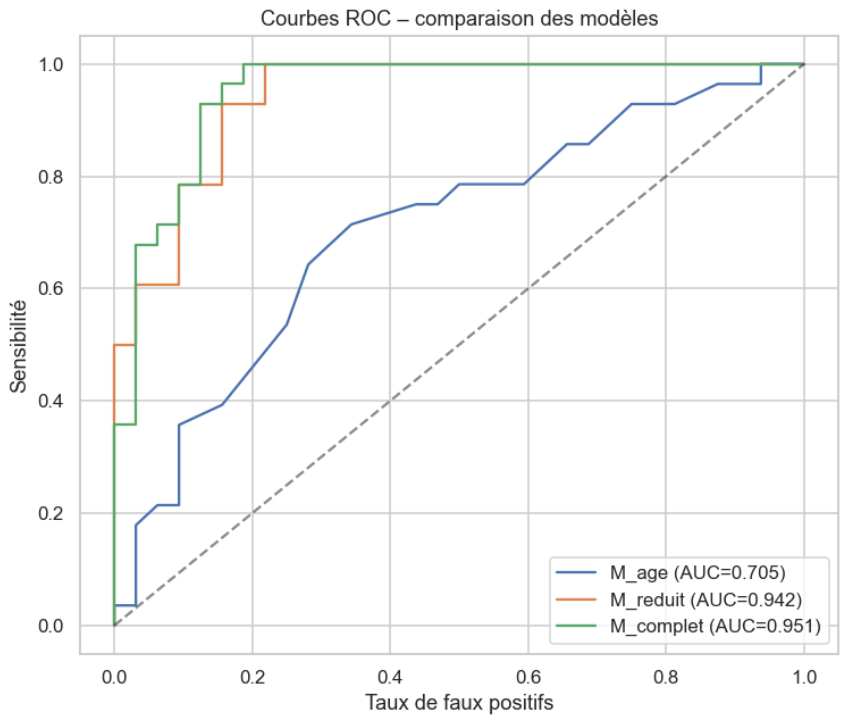

Figure 5.3 – Courbes ROC comparées des trois modèles sur l'échantillon de validation. Le modèle réduit atteint AUC = 0,942, quasi identique au modèle complet (0,951) pour la moitié des paramètres.

5.6 Comparaison des fonctions de lien

Table 5.8 – Comparaison de trois fonctions de lien sur le modèle retenu

Fonction de lien $g(\mu)$	Déviance	AIC
logit $\log \dfrac{\mu}{1-\mu}$	168,19	186,19
probit $\Phi^{-1}(\mu)$	169,07	187,07
cloglog $\log(-\log(1-\mu))$	**167,63**	**185,63**

Les trois liens donnent des résultats statistiquement indistinguables (ΔAIC < 2). Le cloglog est marginalement meilleur, mais le **logit est retenu** pour son interprétabilité en odds ratios, convention médicale incontestée.

5.7 Interprétation clinique

Facteurs de risque dominants.

- `cp = asymptomatique` **(**OR $= 6{,}79$**,** $p < 0{,}001$**) :** un patient présentant des douleurs thoraciques silencieuses a une cote d'être malade *6,79 fois supérieure* à un patient avec angine atypique. Ce résultat est cohérent avec la littérature cardiologique sur les *infarctus silencieux*, qui sont de reconnus facteurs de mortalité.
- `thal = réversible` **(**OR $= 5{,}56$**,** $p < 0{,}001$**) :** un déficit thalassémique réversible détecté au stress-test multiplie par 5,56 la cote de maladie ; c'est un marqueur direct d'ischémie myocardique.
- `ca` **(OR** $= 2{,}46$ **par écart-type,** $p < 0{,}001$**) :** chaque vaisseau coronarien supplémentaire visible à la fluoroscopie multiplie par 2,46 la cote de maladie.
- `slope = plate` **(**OR $= 2{,}51$**,** $p = 0{,}035$**) et** `oldpeak` **(**OR $= 1{,}91$**,** $p = 0{,}014$**) :** anomalies du segment ST à l'effort significativement associées à la maladie.

Facteurs à la limite de significativité ($p \approx 0{,}07$).

- `sex_M` (OR $= 2{,}41$) : les hommes sont environ 2,4 fois plus à risque, effet limite-significatif attribuable à la taille d'échantillon.
- `trestbps` (OR $= 1{,}45$) : la pression artérielle au repos joue un rôle, mais de manière marginale lorsqu'on contrôle des autres covariables.

Facteur protecteur. `restecg = normal` (OR $= 0{,}47$) : un ECG de repos normal divise par deux la cote de maladie, tout en restant à la limite de significativité.

5.8 Limites

- **Effectif modeste** ($n = 297$) : les intervalles de confiance des OR restent larges pour plusieurs variables.

— **Données observationnelles :** les OR n'ont pas valeur causale sans contrôle de variables de confusion supplémentaires.

— **Population spécifique :** données issues de la Cleveland Clinic Foundation ; la généralisabilité à d'autres populations doit être prudente.

— **Validation unique :** une validation croisée k-fold fournirait des estimations plus robustes de l'AUC.

Chapitre 6

Conclusion

6.1 Synthèse

Ce rapport a mis en œuvre la démarche complète de modélisation par *GLM logistique* enseignée par Mme F. Badaoui (INSEA) sur un problème réel de classification médicale. Les étapes suivantes ont été appliquées :

1. Analyse descriptive univariée et bivariée ;
2. Échantillonnage stratifié 80 / 20 ;
3. Ajustement d'un GLM Binomial(1, π) avec fonction de lien logit par maximum de vraisemblance (IRLS) ;
4. Sélection de variables par *backward AIC* (8 variables retenues sur 18) ;
5. Tests de Wald individuels et test du rapport de vraisemblance sur modèles emboîtés ;
6. Tests d'adéquation : déviance, χ^2 de Pearson, test d'Hosmer–Lemeshow, pseudo-R^2, AIC, BIC ;
7. Diagnostic par les résidus de Pearson, de déviance, leviers h_{ii} et distances de Cook ;
8. Évaluation sur l'échantillon de validation par matrice de confusion et courbe ROC ;
9. Comparaison de trois fonctions de lien (logit / probit / cloglog) ;
10. Interprétation clinique via les odds ratios.

6.2 Performance du modèle retenu

Le modèle réduit à 8 variables atteint :

— **AUC** = 0,942 sur l'échantillon de validation ;

— **Accuracy** = 81,7 %, rappel = 78,6 % ;

— Hosmer–Lemeshow $p = 0{,}61$, ratio $D/\text{ddl} = 0{,}74$ (adéquation validée) ;

— Max distance de Cook = 0,073 $\ll 1$ (pas d'observation influente).

Les performances sont *statistiquement équivalentes* à celles du modèle complet (18 variables) tout en étant **deux fois plus parcimonieuses**, conformément au principe d'Ockham.

6.3 Contributions du travail

— **Pédagogique :** démonstration que la démarche du cours est reproductible *à l'identique* en Python, élargissant les possibilités d'analyse pour les étudiants.

— **Scientifique :** identification rigoureuse de quatre facteurs cliniques dominants (type de douleur thoracique, thalassémie réversible, vaisseaux coronariens atteints, anomalies ST) en accord avec la littérature cardiologique.

— **Opérationnelle :** livraison d'un pipeline complet, reproductible et documenté (notebook Jupyter, script Python, figures haute résolution, rapport LaTeX).

6.4 Perspectives

1. **Validation croisée k-fold** pour des estimations plus robustes des métriques de performance.
2. **Ajustement par Firth** (*bias-reduced MLE*) pour gérer les quasi-séparations potentielles.
3. **Termes d'interaction** (ex. `sex` $\times$ `age`) pour raffiner la stratification par sexe.
4. **Comparaison à des modèles non-paramétriques** (random forest, XGBoost) en conservant la régression logistique comme *référence interprétable*.
5. **Étalonnage des probabilités prédites** (méthodes de Platt, isotonique) pour une utilisation clinique où le seuil de décision doit être calibré au risque acceptable.

Bibliographie

[1] Badaoui, F. (2026). *Modèle Linéaire Généralisé*. Polycopié de cours, Institut National de Statistique et d'Économie Appliquée (INSEA), Rabat.

[2] Nelder, J. A. & Wedderburn, R. W. M. (1972). Generalized Linear Models. *Journal of the Royal Statistical Society A*, **135**(3), 370–384.

[3] McCullagh, P. & Nelder, J. A. (1989). *Generalized Linear Models* (2e éd.). Chapman & Hall, London.

[4] Detrano, R., Jánosi, A., Steinbrunn, W., Pfisterer, M., Schmid, J. J., Sandhu, S., Guppy, K. H., Lee, S., & Froelicher, V. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *American Journal of Cardiology*, **64**, 304–310.

[5] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3e éd.). Wiley.

[6] Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley.

[7] Dua, D. & Graff, C. (2019). UCI Machine Learning Repository. *Heart Disease Data Set*. https://archive.ics.uci.edu/ml/datasets/Heart+Disease

[8] Seabold, S. & Perktold, J. (2010). Statsmodels : econometric and statistical modeling with Python. *9th Python in Science Conference*.

[9] Pedregosa, F. *et al.* (2011). Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, **12**, 2825–2830.

[10] Organisation Mondiale de la Santé (2023). *Cardiovascular diseases (CVDs) — Fact sheet*. https://www.who.int/

Annexe A

Code Python utilisé

Le code ci-dessous est l'extrait principal du script `analysis.py` (également disponible sous forme de notebook Jupyter `analysis.ipynb`).

Listing A.1 – Pipeline complet d'analyse par GLM logistique

```python
import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.genmod.families import Binomial
from statsmodels.genmod.families.links import logit, probit, cloglog
from scipy import stats
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import (confusion_matrix, roc_curve, auc,
                             accuracy_score, precision_score,
                             recall_score, f1_score)

# ---- 1. Chargement et preparation ----
cols = ["age","sex","cp","trestbps","chol","fbs","restecg",
        "thalach","exang","oldpeak","slope","ca","thal","num"]
df = pd.read_csv("data/heart_cleveland.csv",
                 header=None, names=cols, na_values="?").dropna()
df["chd"] = (df["num"] > 0).astype(int)
df = df.drop(columns=["num"])

# Recodage des qualitatives
df["sex"] = df["sex"].map({0:"F", 1:"M"})
df["cp"]  = df["cp"].map({1:"angine_typ", 2:"angine_atyp",
                          3:"non_angineuse", 4:"asymptomatique"})
# ... (idem pour fbs, restecg, exang, slope, thal)

qual = ["sex","cp","fbs","restecg","exang","slope","thal"]
quant = ["age","trestbps","chol","thalach","oldpeak","ca"]
X = pd.get_dummies(df.drop(columns="chd"), columns=qual,
                   drop_first=True).astype(float)
y = df["chd"].values

# ---- 2. Echantillonnage stratifie 80/20 ----
X_tr, X_te, y_tr, y_te = train_test_split(
```

```python
    X, y, test_size=0.20, stratify=y, random_state=42)

scaler = StandardScaler()
X_tr[quant] = scaler.fit_transform(X_tr[quant])
X_te[quant] = scaler.transform(X_te[quant])

X_tr_sm = sm.add_constant(X_tr)
X_te_sm = sm.add_constant(X_te)[X_tr_sm.columns]

# ---- 3. Ajustement du GLM logistique ----
m_full = sm.GLM(y_tr, X_tr_sm, family=Binomial(link=logit())).fit()
print(m_full.summary())

# ---- 4. Selection backward AIC ----
def backward_aic(X, y):
    cur = list(X.columns)
    best = sm.GLM(y, X[cur], family=Binomial(link=logit())).fit().aic
    improved = True
    while improved and len(cur) > 1:
        improved = False
        candidats = []
        for c in cur:
            if c == "const": continue
            trial = [k for k in cur if k != c]
            a = sm.GLM(y, X[trial],
                       family=Binomial(link=logit())).fit().aic
            candidats.append((a, c))
        candidats.sort()
        if candidats and candidats[0][0] < best - 1e-3:
            best = candidats[0][0]
            cur.remove(candidats[0][1])
            improved = True
    return cur

sel = backward_aic(X_tr_sm, y_tr)
m_red = sm.GLM(y_tr, X_tr_sm[sel],
               family=Binomial(link=logit())).fit()

# ---- 5. Test du rapport de vraisemblance ----
def lr_test(small, big):
    stat = small.deviance - big.deviance
    ddl  = int(small.df_resid - big.df_resid)
    return stat, ddl, 1 - stats.chi2.cdf(stat, ddl)

# ---- 6. Test de Hosmer-Lemeshow ----
def hosmer_lemeshow(y, p, g=10):
    d = pd.DataFrame({"y": y, "p": p})
    d["bin"] = pd.qcut(d["p"], q=g, duplicates="drop")
    obs = d.groupby("bin")["y"].agg(["sum","count"])
    pi = d.groupby("bin")["p"].mean().values
    o1, n = obs["sum"].values, obs["count"].values
    e1 = n * pi
```

```
    C = np.sum((o1 - e1)**2 / (n * pi * (1 - pi)))
    ddl = len(o1) - 2
    return C, ddl, 1 - stats.chi2.cdf(C, ddl)

C, ddl, p = hosmer_lemeshow(y_tr, m_red.fittedvalues, g=10)

# ---- 7. Analyse des residus ----
infl = m_red.get_influence()
res_p = m_red.resid_pearson
res_d = m_red.resid_deviance
h_ii  = infl.hat_matrix_diag
cook  = infl.cooks_distance[0]

# ---- 8. Validation : matrice de confusion + ROC ----
p_hat = m_red.predict(X_te_sm[sel])
y_hat = (p_hat >= 0.5).astype(int)
cm    = confusion_matrix(y_te, y_hat)
fpr, tpr, _ = roc_curve(y_te, p_hat)
AUC   = auc(fpr, tpr)

# ---- 9. Odds ratios et IC95% ----
params = m_red.params
ci     = m_red.conf_int()
OR_table = pd.DataFrame({
    "beta": params,
    "OR":   np.exp(params),
    "IC_low":  np.exp(ci[0]),
    "IC_high": np.exp(ci[1]),
    "pvalue": m_red.pvalues
})
```

Ressources livrées avec ce rapport.

- `analysis.py` — script Python complet (500 lignes).
- `analysis.ipynb` — notebook Jupyter exécuté.
- `results.txt` — sortie console intégrale.
- `odds_ratios.csv` — tableau des OR du modèle retenu.
- `figures/` — 7 figures haute résolution (PNG).
- `presentation.tex` — support de soutenance Beamer.